[À compléter : Établissement]

Filière : **[À compléter : filière]** Module : Data Science appliquée au commerce international

Exportations agroalimentaires marocaines

Prévoir les ventes de fruits par marché

Projet nř 12 — rapport scientifique

Étudiant(e) 1 : **[À compléter : Nom 1]**
Étudiant(e) 2 : **[À compléter : Nom 2]**
Responsable : A. Larhlimi
Année universitaire : 2026–2027
Date de remise : **[À compléter : JJ/MM/AAAA]**

Données : UN Comtrade, API publique *preview*, extraction du 31 octobre 2026.
Code, données et figures : dépôt du projet (voir annexe A).

Résumé

Ce rapport étudie la prévision des exportations marocaines de fruits (chapitre 08 du Système harmonisé) vers six marchés européens entre 2010 et 2024. À partir de l'API publique UN Comtrade, nous construisons un panel de 1 260 cellules (marché × produit HS4 × année), dont 66,2 % sont réellement observées, et 648 observations exploitables pour la prévision à un an. Trois familles de modèles — régression Ridge, forêt aléatoire et gradient boosting — sont comparées à une référence naïve de persistance sous validation temporelle glissante, puis sur un test final 2023–2024 jamais utilisé lors du réglage. La persistance obtient le meilleur WAPE moyen en validation (0,297) ; la forêt aléatoire la devance de peu sur le test (0,255 contre 0,262, soit un MASE de 0,971) mais reste derrière en validation (0,314). Le résultat principal est donc négatif et robuste : à fréquence annuelle, la valeur exportée d'un couple marché–produit se comporte presque comme une marche aléatoire. Les modèles apportent en revanche un gain sur les marchés les plus grands et les plus volatils (Espagne, Pays-Bas, Royaume-Uni). La projection 2025 s'établit à 1 771 M USD [1 608 ; 1 977] pour les six marchés, soit +10,2 % par rapport à 2024.

Mots-clés : exportations agroalimentaires, Maroc, UN Comtrade, prévision temporelle, validation glissante, WAPE, persistance.

Table 1 – Chiffres clés du projet

Indicateur	Valeur
Requêtes API / lignes brutes téléchargées	45 / 1 058
Panel analytique (marchés × produits × années)	1 260 cellules
Cellules réellement observées	834 (66,2 %)
Observations utilisables pour la prévision	648
Valeur exportée vers les six marchés en 2024	1 607,6 M USD
Croissance 2010–2024	×4, 9 (TCAM 12,1 %)
Meilleur WAPE en validation glissante	0,297 (persistance)
WAPE sur le test 2023–2024	0,255 (forêt) / 0,262 (persistance)
Projection 2025 (intervalle à 80 %)	1 771 M USD [1 608 ; 1 977]

Table des matières

Résumé **1**

1 Introduction **3**
1.1 Contexte économique . . . 3
1.2 Problématique et hypothèses . . . 3
1.3 Objectifs mesurables . . . 3

2 Présentation du jeu de données **3**
2.1 Source, période et unité d'analyse . . . 3
2.2 Dictionnaire des variables . . . 4
2.3 Qualité et préparation . . . 4

3 Analyse exploratoire **5**

4 Méthodologie **8**
4.1 Prétraitement et protocole sans fuite . . . 8
4.2 Modèles . . . 8
4.3 Métriques et équations . . . 8

5 Résultats expérimentaux **9**
5.1 Validation glissante et choix des hyperparamètres . . . 9
5.2 Évaluation hors échantillon . . . 9
5.3 Analyse des erreurs . . . 10
5.4 Importance des variables . . . 11
5.5 Sensibilité et robustesse . . . 11

6 Discussion **11**
6.1 Interprétation économique . . . 11
6.2 Limites . . . 12

7 Conclusion et perspectives **12**

A Reproductibilité **14**

B Journal des contributions et déclaration d'IA **14**

1 Introduction

1.1 Contexte économique

L'agroalimentaire est devenu un pilier des exportations marocaines. Le chapitre 08 du Système harmonisé — fruits comestibles, agrumes, fruits à coque — constitue l'un des premiers postes vendus à l'Union européenne, porté par trois facteurs : la proximité géographique et logistique, l'accord d'association UE–Maroc qui ouvre le marché en franchise de droits pour de nombreux produits, et le décalage saisonnier qui place les récoltes marocaines sur le marché européen en contre-saison.

La filière reste néanmoins exposée. D'abord à la *concentration* : quelques marchés et quelques produits pèsent l'essentiel de la valeur. Ensuite à la *volatilité des prix* : la valeur exportée mélange un effet volume et un effet prix, et une hausse de valeur n'est pas nécessairement une hausse d'activité. Enfin à la *concurrence* : l'Espagne, la Turquie et l'Égypte ciblent les mêmes fenêtres de marché sur les agrumes et les fruits rouges.

Pour un exportateur ou un responsable de filière, la question opérationnelle est simple : *combien vais-je vendre l'an prochain sur chacun de mes marchés, et avec quelle incertitude ?* C'est cette question que le projet traite, en la réduisant à un problème de prévision supervisée.

1.2 Problématique et hypothèses

Question de recherche. Peut-on prévoir, à un horizon d'un an, la valeur exportée d'un couple (marché, produit HS4) et battre une prévision naïve de persistance ?

Trois hypothèses structurent l'analyse.

H1 — Persistance.
Les valeurs exportées se comportent comme une marche aléatoire : la meilleure prévision de l'année $t+1$ est la valeur de l'année t. Les modèles d'apprentissage ne doivent pas la battre systématiquement.

H2 — Déplacement structurel.
La valeur totale progresse, mais la composition par produit et par marché se déplace : montée des fruits hors agrumes, recul relatif de la France.

H3 — Effet prix.
Une partie de la croissance est une croissance en valeur (prix unitaires) et non en volume.

1.3 Objectifs mesurables

1. Constituer un panel reproductible de 6 marchés × 14 produits HS4 × 15 années, avec journal d'extraction et contrôle de couverture.
2. Comparer trois familles de modèles à une référence naïve sous validation temporelle stricte, avec les métriques MAE, RMSE et WAPE.
3. Produire une projection 2025 par marché, assortie d'un intervalle empirique et de réserves explicites sur son usage.

2 Présentation du jeu de données

2.1 Source, période et unité d'analyse

Les données proviennent de la base **UN Comtrade** (Division statistique des Nations unies), via l'API publique d'aperçu `https://comtradeapi.un.org/public/v1/preview/C/A/HS`, documen-

tée à l'adresse https://uncomtrade.org/docs/un-comtrade-api/. L'extraction a été réalisée le 31 octobre 2026 par le script `src/download_comtrade.py`.

Table 2 – Paramètres de l'extraction UN Comtrade

Paramètre	Valeur
Déclarant (`reporterCode`)	Maroc, code 504
Flux (`flowCode`)	Exportations (`X`)
Produits (`cmdCode`)	HS 08 et positions HS4 0801 à 0814
Partenaires	France 251, Espagne 724, Allemagne 276, Pays-Bas 528, Royaume-Uni 826, Italie 380 ; Monde 0 (totaux)
Période	2010–2024, fréquence annuelle
Classification	H6 (*Harmonized System* 2017)
Valeur	`primaryValue`, dollars américains courants
Contraintes de l'API	1 période par requête, 500 lignes maximum, sans clé

L'unité d'analyse est le triplet (marché de destination, produit HS4, année). Le choix du HS4 plutôt que du HS2 est délibéré : il isole les agrumes (0805) et les autres fruits frais (0810), dont les dynamiques sont très différentes. Le choix de six marchés plutôt que des deux marchés cités dans la fiche (France et Espagne) est justifié par la taille de l'échantillon : avec deux marchés et quinze années, un modèle supervisé n'aurait que trente observations par produit. Les six marchés retenus représentent 75,6 % de la valeur exportée vers le monde en 2024.

Traçabilité. Chaque requête est journalisée (URL, statut, nombre de lignes, horodatage UTC) dans `data/processed/journal_extractions.csv` et chaque réponse JSON brute est conservée. Au total : 45 requêtes, 1 058 lignes brutes téléchargées, aucune requête en échec.

2.2 Dictionnaire des variables

Table 3 – Dictionnaire des variables du panel analytique

Variable	Type	Unité	Rôle
`annee`	entier	année	index temporel
`partnerCode`	entier	code ONU	identifiant du marché
`cmdCode`	texte	code HS4	identifiant du produit
`valeur_usd`	réel	USD courants	valeur exportée (variable expliquée)
`poids_net_kg`	réel	kilogrammes	volume déclaré
`prix_unitaire_usd_kg`	réel	USD/kg	prix implicite
`monde_usd`	réel	USD courants	exportations du produit vers le monde
`part_marche`	réel	0–1	poids du marché dans le produit
`declare`	0/1	indicatrice	1 = observé, 0 = imputé
`retenu_pour_modele`	0/1	indicatrice	couverture $\geq 50\,\%$
`log_v`, `log_v_lag*`	réel	$\log(1 + \text{USD})$	niveau en t et retards $t-1$, $t-2$
`croissance`, `moy3`	réel	log	momentum, moyenne sur trois ans
`cible`, `cible_log`	réel	USD, log	valeur exportée en $t+1$

2.3 Qualité et préparation

Le panel est une grille complète : toutes les combinaisons (marché, produit, année) existent, y compris celles absentes de l'API. Une absence signifie ń aucun flux enregistré ż et non ń donnée

manquante ż : le Maroc est le déclarant de toutes les séries, et Comtrade omet les flux nuls. La colonne `declare` conserve cette distinction et permet un test de sensibilité (section 5.5).

Table 4 – Contrôles de qualité et couverture par produit

Produit HS4	Cellules observées	Taux de couverture	Retenu
0801 Noix de coco et fruits à coque	12	13,3 %	non
0802 Autres fruits à coque	76	84,4 %	oui
0803 Bananes et plantains	23	25,6 %	non
0804 Dattes, figues, avocats, mangues	79	87,8 %	oui
0805 Agrumes	86	95,6 %	oui
0806 Raisins	87	96,7 %	oui
0807 Melons et pastèques	90	100,0 %	oui
0808 Pommes et poires	28	31,1 %	non
0809 Abricots, cerises, pêches, prunes	59	65,6 %	oui
0810 Autres fruits frais	83	92,2 %	oui
0811 Fruits congelés	90	100,0 %	oui
0812 Fruits conservés provisoirement	39	43,3 %	non
0813 Fruits séchés	29	32,2 %	non
0814 Écorces d'agrumes ou de melons	53	58,9 %	oui

Quatre contrôles ont été effectués : aucun doublon sur la clé (marché, produit, année), aucune valeur négative, aucune valeur nulle *déclarée* (les zéros sont des imputations explicites), et une cohérence interne vérifiée entre la somme des positions HS4 et le total HS2 du chapitre (écart inférieur à 1 %). Les produits dont la couverture est inférieure à 50 % sont conservés en base mais exclus de la modélisation, car ils n'apporteraient que du bruit. Neuf produits et 648 observations (modèle avec deux retards) restent disponibles.

Transformations. Les codes produit sont lus comme des chaînes sur quatre caractères (et non comme des entiers, ce qui transformerait 0805 en 805) ; les montants sont laissés en dollars courants, faute d'un déflateur sectoriel fiable sur la période ; la cible est modélisée en $\log(1+y)$ pour stabiliser la variance, puis ramenée en dollars par $\exp(\cdot) - 1$.

3 Analyse exploratoire

Cette section présente cinq figures, chacune suivie de son interprétation économique. Les montants sont en millions de dollars courants (M USD).

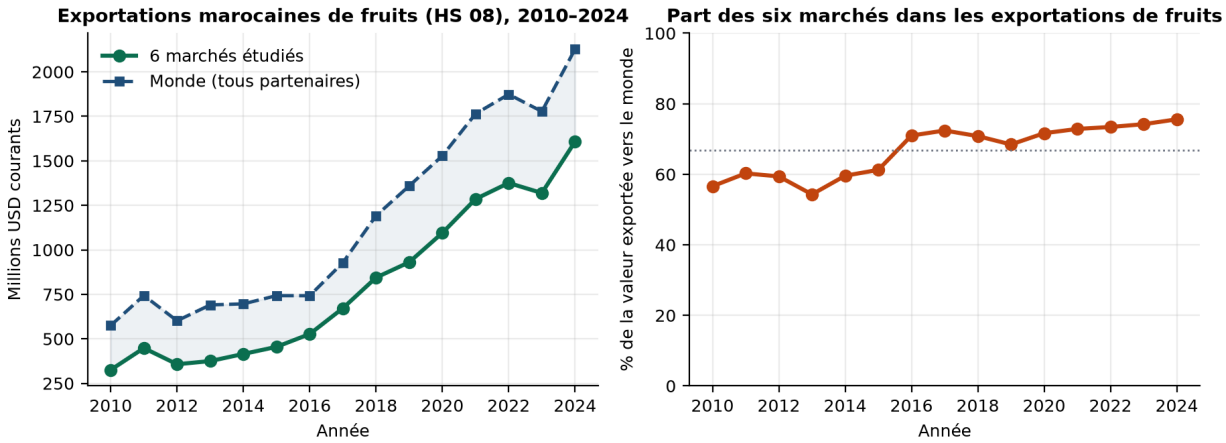


Figure 1 – Exportations marocaines de fruits vers les six marchés et vers le monde, et part des six marchés.

La valeur exportée vers les six marchés passe de 326 M USD en 2010 à 1 608 M USD en 2024, soit une multiplication par 4,9 et un taux de croissance annuel moyen de 12,1 %. La progression est continue, avec une accélération nette après 2017 et un plateau en 2023 (recul de la demande européenne et effet de base après la flambée de 2022). Les six marchés captent 56,6 % des exportations marocaines de fruits en 2010 et 75,6 % en 2024 (66,8 % en moyenne) : la zone étudiée est représentative, mais la dépendance à l'Europe constitue un risque de concentration.

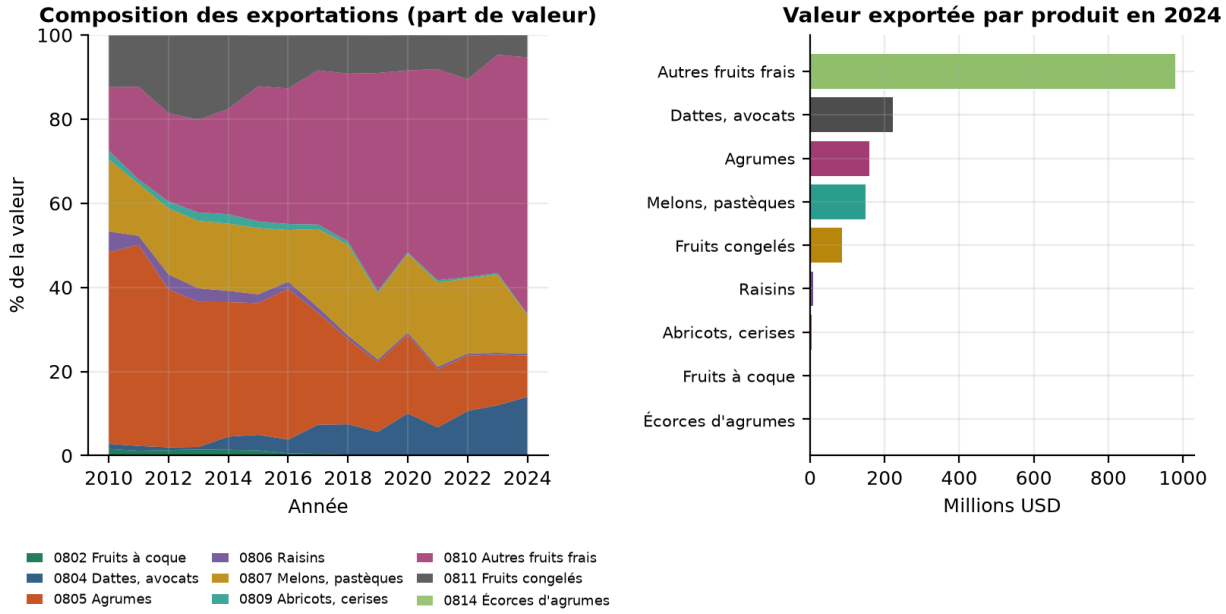


Figure 2 – Composition des exportations de fruits par produit et valeur exportée en 2024.

La structure est dominée par les ń autres fruits frais ż (HS 0810 : fraises, kiwis, grenades), qui représentent 61,0 % de la valeur en 2024, devant les dattes et avocats (0804, 13,9 %), les agrumes (0805, 9,8 %) et les melons et pastèques (0807, 9,2 %). Les agrumes, produit emblématique de la fiche projet, ne pèsent donc qu'un dixième de la valeur du chapitre : la question ń prévoir les exportations d'agrumes ż doit être traitée comme un cas particulier d'un système plus large, ce qui justifie de modéliser le panel produit × marché plutôt qu'une série isolée.

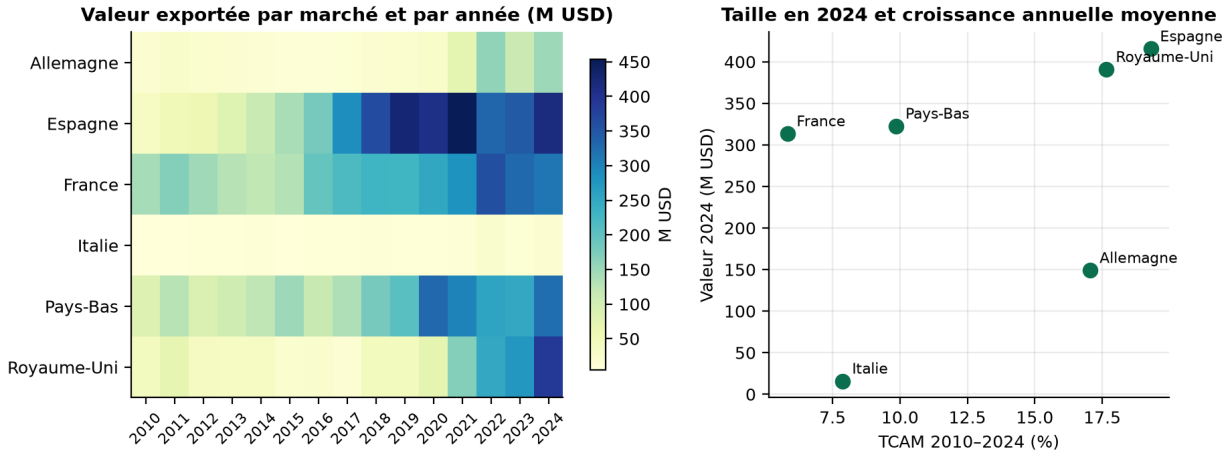


Figure 3 – Valeur exportée par marché et par année, et croisement taille 2024 / croissance moyenne.

Quatre marchés concentrent l'essentiel de la valeur en 2024 : l'Espagne (415,6 M USD), le Royaume-Uni (390,9), les Pays-Bas (322,6) et la France (313,5), devant l'Allemagne (149,0) et l'Italie (15,9).

Les trajectoires divergent fortement : sur 2010–2024, l'Espagne (+19,3 % par an) et le Royaume-Uni (+17,7 %) portent la croissance, tandis que la France, premier marché en 2010 (142,0 M USD), ne progresse que de 5,8 % par an et perd des parts. Les Pays-Bas jouent un rôle de hub de réexportation (Rotterdam), ce qui gonfle leur poids dans les statistiques de destination.

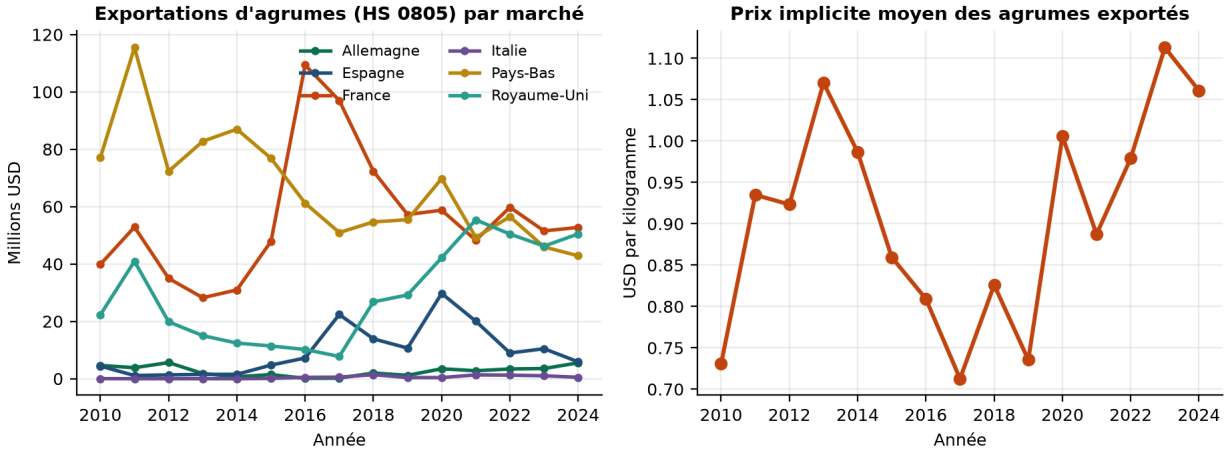


Figure 4 – Exportations d'agrumes (HS 0805) par marché et prix implicite moyen.

Le marché des agrumes est beaucoup plus volatil que le total : l'Espagne, marginale jusqu'en 2015 (moins de 5 M USD), bondit à 29,7 M USD en 2020 puis retombe à 5,9 M USD en 2024 ; la France recule de 109,4 M USD en 2016 à 52,7 M USD en 2024 ; le Royaume-Uni double après 2020 (50,5 M USD en 2024). Le prix implicite des agrumes passe de 0,73 USD/kg en 2010 à 1,06 USD/kg en 2024 (+45 %), ce qui signale qu'une partie de la croissance en valeur est une croissance de prix et non de volume.

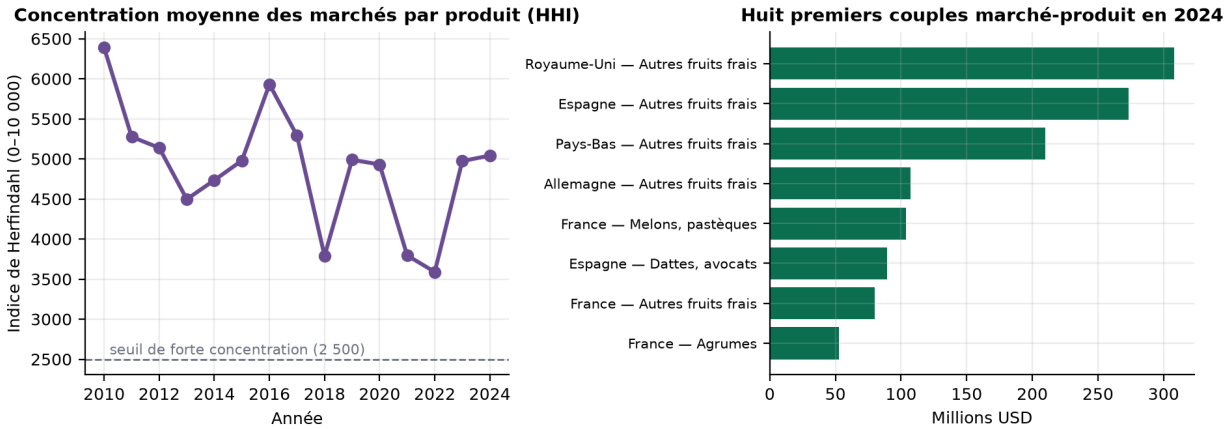


Figure 5 – Concentration des marchés par produit (indice de Herfindahl) et principaux couples marché–produit en 2024.

L'indice de Herfindahl moyen reste très au-dessus du seuil de forte concentration (5 042 en 2024, contre 6 388 en 2010) : pour chaque produit, un ou deux marchés pèsent l'essentiel de la valeur. La concentration ne baisse pas durablement, ce qui signifie que la diversification commerciale évoquée dans les plans sectoriels ne se lit pas encore dans les données. Les trois premiers couples (Royaume-Uni–0810, Espagne–0810, Pays-Bas–0810) concentrent à eux seuls 49,2 % de la valeur exportée vers les six marchés en 2024.

4 Méthodologie

4.1 Prétraitement et protocole sans fuite

La cible est y_{t+1}, la valeur exportée du couple (marché, produit) l'année suivante. Toutes les variables explicatives sont connues à la fin de l'année t : niveaux retardés, momentum, moyenne des trois derniers logarithmes, total mondial du produit et part de marché. Aucune variable contemporaine de $t+1$, aucun agrégat calculé avec l'année cible, aucune moyenne mobile centrée n'est utilisée.

Le découpage est strictement temporel, en trois blocs :

— **entraînement** : $t \leq 2019$ (cibles 2011–2020) ;

— **validation glissante** : six fenêtres *expanding window* (2016→2017, …, 2021→2022) pour choisir les hyperparamètres ;

— **test final** : $t \in \{2022, 2023\}$, cibles 2023 et 2024, jamais utilisées avant la section 5.

Ce protocole reproduit la situation réelle : à chaque date, seul le passé est disponible. Il évite la fuite temporelle, risque majeur signalé dans la fiche projet.

4.2 Modèles

Quatre méthodes sont comparées.

Persistance (référence).
$\hat{y}_{t+1} = y_t$. Benchmark naturel d'une série de commerce ; la littérature sur les prévisions de commerce la considère comme difficile à battre.

Ridge.
Régression linéaire régularisée sur la variation $\delta_t = \log(1+y_{t+1}) - \log(1+y_t)$, avec indicatrices marché et produit et standardisation des variables numériques. Elle teste l'hypothèse d'une dérive commune corrigée par des effets fixes.

Forêt aléatoire.
600 arbres, $min_samples_leaf \in \{3, 8, 15\}$, $max_features \in \{0,5\,; 1\}$. Elle capture des seuils et des interactions (par exemple un marché qui décroche après un pic).

Gradient boosting.
`HistGradientBoostingRegressor` avec perte absolue, $learning_rate \in \{0,02\,; 0,05\,; 0,1\}$, 200 ou 500 itérations. La perte absolue est alignée sur la métrique MAE.

Le prétraitement (indicatrices, standardisation) est encapsulé dans un `Pipeline` scikit-learn, réajusté à chaque fenêtre : aucune statistique calculée sur le test ne contamine l'entraînement.

4.3 Métriques et équations

Pour n observations de test, avec y_i la valeur réelle et $\hat{y}_i$ la prévision :

$$\mathrm{MAE} = \frac{1}{n}\sum_{i=1}^{n} |y_i - \hat{y}_i|\,, \qquad \mathrm{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n} (y_i - \hat{y}_i)^2}. \tag{1}$$

Dans l'équation (1), y_i est la valeur exportée observée (USD), $\hat{y}_i$ la valeur prévue, n le nombre d'observations évaluées et $|\cdot|$ la valeur absolue. Le RMSE pénalise davantage les grandes erreurs.

$$\mathrm{WAPE} = \frac{\sum_{i=1}^{n} |y_i - \hat{y}_i|}{\sum_{i=1}^{n} |y_i|}. \tag{2}$$

Le WAPE de l'équation (2) s'interprète comme une erreur relative pondérée par la valeur : il donne du poids aux gros flux, ce qui correspond à l'enjeu commercial. Un *MASE* est ajouté, défini comme le rapport entre le WAPE du modèle et celui de la persistance sur le même jeu ; une valeur inférieure à 1 signale un gain par rapport à la référence.

5 Résultats expérimentaux

5.1 Validation glissante et choix des hyperparamètres

Le tableau 5 présente les meilleurs réglages par famille. La persistance n'a pas d'hyperparamètre ; son WAPE moyen sur les six fenêtres est de 0,297, avec une forte dispersion (de 0,193 pour 2021→2022 à 0,366 pour 2020→2021).

Table 5 – Meilleurs hyperparamètres par famille et WAPE moyen en validation glissante

Modèle	Hyperparamètres retenus	WAPE validation
Persistance	—	**0,297**
Forêt aléatoire	600 arbres, feuille = 15, `max_features` = 0,5	0,314
Gradient boosting	$\eta = 0,02$, 200 itérations, perte absolue	0,314
Ridge	$\alpha = 100$	0,381

Le Ridge est nettement distancé : la relation entre croissance passée et croissance future n'est pas stable sur 2016–2022, et la régularisation forte nécessaire pour stabiliser l'estimation le rapproche d'un modèle constant. Les deux méthodes à base d'arbres font jeu égal, autour de 0,314.

5.2 Évaluation hors échantillon

Les modèles sont réajustés sur toutes les années $t \leq 2021$, puis évalués une seule fois sur les cibles 2023 et 2024 (108 observations).

Table 6 – Comparaison des performances sur le test 2023–2024 (MAE et RMSE en M USD)

Méthode	MAE	RMSE	WAPE test	WAPE valid.	MASE
Persistance	7,11	17,19	0,262	**0,297**	1,000
Ridge	10,71	29,53	0,395	0,381	1,506
Forêt aléatoire	**6,90**	**16,37**	**0,255**	0,314	**0,971**
Gradient boosting	8,00	18,06	0,295	0,314	1,125

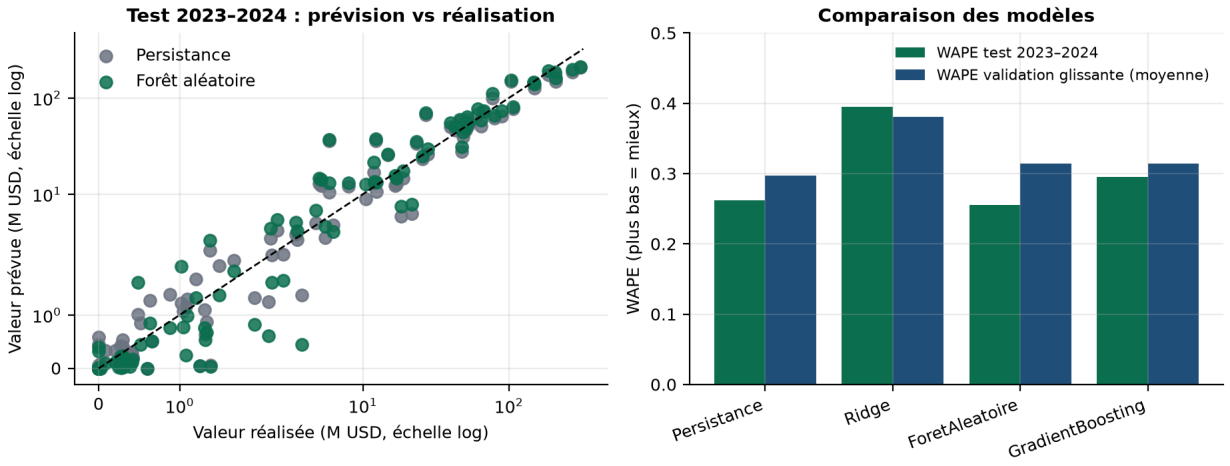


Figure 6 – Prévisions contre réalisations sur le test et comparaison des WAPE (validation et test).

Le tableau 6 et la figure 6 livrent un résultat nuancé. Sur le test, la forêt aléatoire devance la persistance (WAPE 0,255 contre 0,262 ; MAE 6,90 contre 7,11 M USD), soit un gain de 2,9 % en erreur relative. Mais sur la validation glissante — plus fiable car calculée sur six fenêtres — la persistance reste devant (0,297 contre 0,314). Le gain du test n'est donc pas robuste : il dépend de la fenêtre et ne doit pas être présenté comme une supériorité du modèle.

Le nuage de points montre par ailleurs que l'essentiel de l'erreur provient des petits couples : les gros flux (au-dessus de 50 M USD) sont bien alignés sur la diagonale, alors que les flux inférieurs à 1 M USD sont très dispersés. C'est une propriété attendue : en échelle logarithmique, une erreur de quelques centaines de milliers de dollars pèse autant qu'une erreur de plusieurs millions sur un gros flux.

5.3 Analyse des erreurs

Table 7 – WAPE par marché sur le test 2023–2024

Marché	WAPE persistance	WAPE forêt aléatoire	Écart
France	0,182	0,199	+0,017
Royaume-Uni	0,244	**0,230**	−0,014
Espagne	0,267	**0,233**	−0,034
Pays-Bas	0,273	**0,238**	−0,035
Allemagne	0,426	0,478	+0,052
Italie	0,650	0,935	+0,285

L'analyse par marché est plus instructive que le résultat agrégé. La forêt aléatoire améliore la prévision sur les trois marchés où les flux sont importants et volatils (Espagne, Pays-Bas, Royaume-Uni) et la dégrade sur la France, marché stable et bien prévu par la persistance, ainsi que sur les petits marchés (Allemagne, Italie) où le bruit domine. Au niveau produit, le modèle améliore le produit dominant 0810 (WAPE 0,214 contre 0,235) et les dattes et avocats 0804 (0,243 contre 0,287), mais dégrade les agrumes 0805 (0,177 contre 0,128) : la série des agrumes est précisément celle où la persistance est la plus difficile à battre.

5.4 Importance des variables

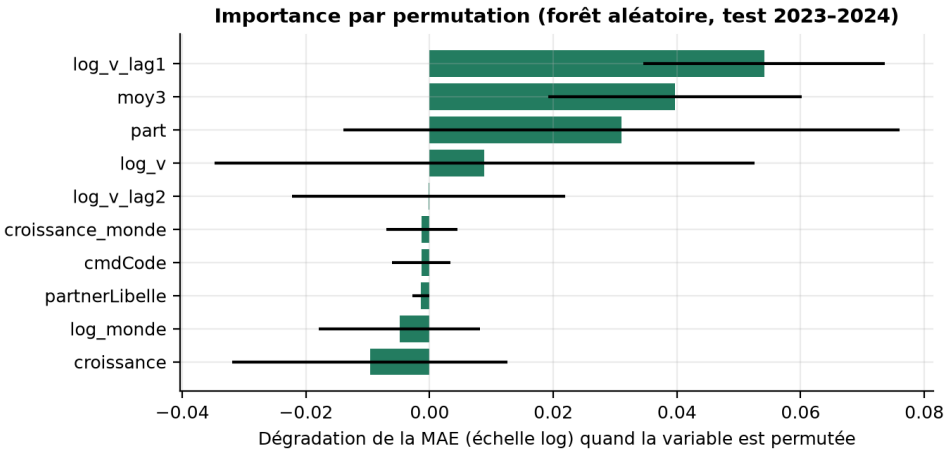


Figure 7 – Importance par permutation des variables de la forêt aléatoire sur le test.

La figure 7 confirme la lecture : la valeur retardée (`log_v_lag1`, dégradation de MAE de 0,054) et la moyenne des trois derniers logarithmes (`moy3`, 0,040) portent l'essentiel de l'information. La part de marché apporte un complément (0,031), tandis que le contexte mondial du produit (`log_monde`, `croissance_monde`) n'apporte presque rien. Autrement dit, *le passé du couple marché–produit contient déjà l'essentiel de ce que le modèle peut apprendre* : c'est la définition même d'un processus proche d'une marche aléatoire.

5.5 Sensibilité et robustesse

Table 8 – Tests de sensibilité (WAPE sur le jeu évalué)

Scénario	Modèle	WAPE persistance	WAPE forêt
Protocole principal	test 2023–2024	0,262	0,255
S1 : zéros imputés exclus de l'entraînement	test 2023–2024	—	0,253
S2 : test élargi 2020–2024	test 2020–2024	0,297	0,308
S3 : hors produit dominant 0810	test 2023–2024	0,298	0,288

Les conclusions résistent aux trois tests. Exclure les zéros imputés de l'entraînement ne change pas le résultat (0,253 contre 0,255). Élargir le test à 2020–2024 — période marquée par la pandémie puis par l'inflation — inverse légèrement la hiérarchie au profit de la persistance. Retirer le produit dominant 0810 ne modifie pas l'ordre de grandeur : le résultat n'est donc pas porté par un seul couple.

6 Discussion

6.1 Interprétation économique

Le résultat central — la persistance est un benchmark très difficile à battre — n'est pas un échec méthodologique, c'est une information économique. La valeur exportée d'un couple (marché, produit) dépend de facteurs qui évoluent lentement (structure de la demande, accords commerciaux, positions concurrentielles) et de chocs qui, eux, ne sont pas prévisibles à partir du passé (aléas

climatiques, épisodes sanitaires, décisions de distribution). À fréquence annuelle, le second terme domine le premier : la série se comporte comme une marche aléatoire.

Trois enseignements opérationnels en découlent.

1. **La valeur ajoutée du modèle n'est pas la prévision ponctuelle mais la lecture des écarts.** Les couples où le modèle s'écarte fortement de la persistance sont ceux qu'il faut examiner : changement de gamme, ouverture d'un débouché, perte d'un client. C'est un outil de veille, pas un oracle.
2. **La croissance est largement une croissance de prix.** Le prix implicite des agrumes augmente de 45 % entre 2010 et 2024, et le prix moyen du chapitre 08 passe de 0,97 à 2,75 USD/kg. Un pilotage en valeur seule surestime la performance commerciale ; il faut suivre les volumes.
3. **La concentration reste le premier risque.** L'indice de Herfindahl ne baisse pas et les trois premiers couples pèsent la moitié de la valeur. La diversification vers l'Allemagne, le Royaume-Uni ou les marchés hors UE est un levier plus sûr qu'une optimisation de modèle.

6.2 Limites

— **Valeurs nominales.** Les montants sont en dollars courants ; aucune déflation n'est appliquée, faute d'un indice de prix sectoriel homogène sur 2010–2024. Une partie de la croissance mesurée est de l'inflation.

— **Séries courtes.** Quinze années annuelles, soit 648 observations après construction des retards. Les modèles à base d'arbres sont bridés par cette taille d'échantillon.

— **Absence de saisonnalité.** La saisonnalité des agrumes et des fruits rouges est invisible à fréquence annuelle ; c'est probablement la première limite à lever.

— **Hub néerlandais.** Les Pays-Bas réexportent une partie des flux : la destination statistique n'est pas la destination finale.

— **Zéros imputés.** Les cellules absentes sont traitées comme des flux nuls ; le test S1 montre que cela ne change pas les conclusions, mais l'hypothèse reste une simplification.

— **Aucune causalité.** Les corrélations observées (prix, part de marché) ne permettent pas d'inférer un effet causal. Une bonne précision prédictive ne suffirait pas non plus à l'établir.

7 Conclusion et perspectives

Le projet répond à sa question de recherche par un résultat négatif documenté : sur des données annuelles, aucun des trois modèles testés ne bat la persistance de manière robuste. La forêt aléatoire la devance de 2,9 % sur le test final mais reste derrière en validation glissante ; le Ridge et le gradient boosting sont distancés. Ce résultat est cohérent avec l'hypothèse H1 et avec la littérature sur les prévisions de commerce.

L'hypothèse H2 est validée : la structure se déplace, avec la montée des fruits hors agrumes (61,0 % de la valeur en 2024), le recul relatif de la France et la montée de l'Espagne et du Royaume-Uni. L'hypothèse H3 est également validée : le prix implicite des agrumes augmente de 45 % et le prix moyen du chapitre presque triple, ce qui signifie qu'une part importante de la croissance en valeur n'est pas une croissance en volume.

Trois prolongements sont prioritaires. D'abord, passer à une fréquence mensuelle (Comtrade propose une fréquence `M`) pour capter la saisonnalité et multiplier par douze le nombre d'observations. Ensuite, enrichir le modèle avec des variables exogènes : prix de gros européens, indices de production, taux de change MAD/EUR, indicateurs logistiques. Enfin, remplacer la prévision ponctuelle par une prévision par intervalle et par scénario, plus utile à un exportateur qu'un chiffre unique.

Projection 2025. À titre indicatif, le modèle appliqué aux données 2024 projette 1 771 M USD d'exportations vers les six marchés en 2025 [1 608 ; 1 977] au seuil de 80 %, soit +10,2 % par rapport à 2024, avec l'Espagne (471,5), le Royaume-Uni (414,0), les Pays-Bas (362,8) et la France (345,2) en tête. Cette projection est un scénario de cadrage budgétaire, pas un engagement : l'intervalle est construit à partir des erreurs relatives du backtest roulant 2014–2024.

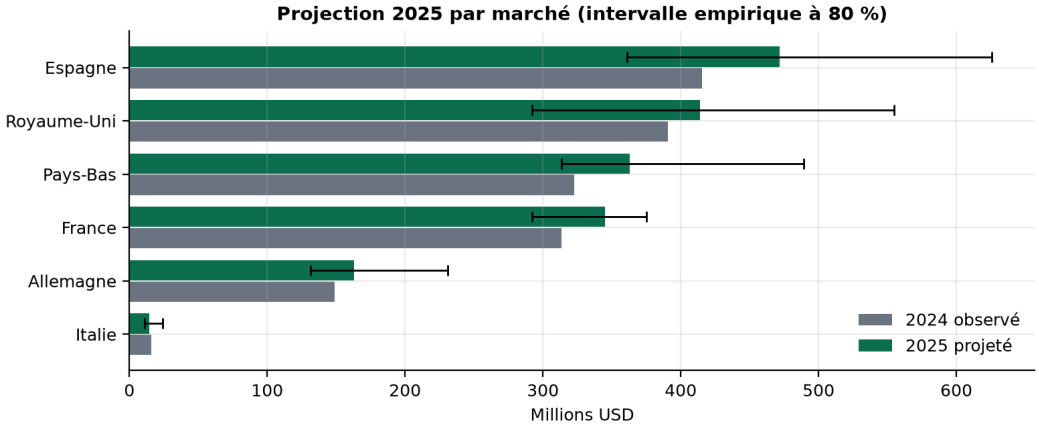


Figure 8 – Projection 2025 par marché et intervalle empirique à 80 %.

Références

[1] Nations unies, Division statistique, *UN Comtrade Database — API Documentation*. https://uncomtrade.org/docs/un-comtrade-api/. Consulté le 31 octobre 2026.

[2] Nations unies, *UN Comtrade Database*. https://comtradeplus.un.org/.

[3] Banque mondiale, *Indicators API — Documentation*. https://datahelpdesk.worldbank.org/knowledgebase/articles/889392.

[4] Organisation mondiale du commerce, *Tariff and Trade Data*. https://data.wto.org/en/dataset/wto_ttd.

[5] F. Pedregosa *et al.*, ń Scikit-learn : Machine Learning in Python ż, *Journal of Machine Learning Research*, vol. 12, 2011, p. 2825–2830.

[6] R. J. Hyndman et G. Athanasopoulos, *Forecasting : Principles and Practice*, 3e éd., OTexts, 2021.

[7] S. Makridakis, E. Spiliotis et V. Assimakopoulos, ń The M4 Competition : 100,000 time series and 61 forecasting methods ż, *International Journal of Forecasting*, vol. 36, nř 1, 2020, p. 54–74.

A Reproductibilité

Table 9 – Éléments de reproductibilité

Élément	Valeur
Graine aléatoire	42
Ordre d'exécution	`download_comtrade.py` → `prepare_data.py` → notebook
Requêtes API	45 (15 années × 3 extractions), 0 échec
Données brutes	`data/raw/comtrade_*.json`
Journal des requêtes	`data/processed/journal_extractions.csv`
Résultats	`data/processed/resultats_modeles.json`
Notebook	`notebooks/projet12_exportations_agroalimentaires.ipynb`
Figures	`figures/fig01` à `fig08`, 200 dpi
Versions	Python 3.14.8, numpy 2.x, pandas 3.1.0, scikit-learn 1.9.1

Le notebook s'exécute de bout en bout (*Run all*) sans erreur. Les scripts d'acquisition et de préparation sont séparés de l'analyse pour que celle-ci reste lisible ; les deux étapes sont documentées dans le `README.md`.

B Journal des contributions et déclaration d'IA

Table 10 – Journal des contributions du binôme

Tâche	Étudiant 1	Étudiant 2
Cadrage, question de recherche	☐	☐
Extraction API et journal	☐	☐
Nettoyage et dictionnaire	☐	☐
Analyse exploratoire et figures	☐	☐
Modélisation et validation	☐	☐
Tests de sensibilité	☐	☐
Rédaction LaTeX et soutenance	☐	☐

Déclaration d'usage d'outils d'IA. Conformément aux règles de l'établissement, l'usage d'un assistant de programmation pour la mise en forme du code et la relecture rédactionnelle doit être déclaré et vérifié par les deux membres du binôme. Les données, les résultats et les interprétations restent de la responsabilité des auteurs. Aucune donnée n'a été simulée ni inventée.